

REPORTE DE AVANCES

Sistema de conteo automatico de alevines

Deep learning y vision artificial movil

CITE Productivo Madre de Dios · 2026

233

imagenes etiquetadas

0.836

mAP@50 (deteccion)

97%

exactitud de conteo*

0.17%

error a nivel de lote

*mediana por imagen del mejor modelo

Este reporte resume el desarrollo completo del sistema: captura de datos, tratamiento y etiquetado, entrenamiento y comparacion de modelos YOLO, evaluacion de deteccion y conteo, tracking para video, y el diseno de una estacion de captura estandarizada.

● Datos

257 fotos + 4 videos (2 sesiones: Android mayo, iPhone julio). 233 imagenes revisadas a mano, 20 701 alevines etiquetados.

● Etiquetado colaborativo

Pre-etiquetado con IA (SAM/YOLO) + revision de 2 anotadores humanos, sincronizado por Git. Clase unica 'alevin'.

● Metodologia rigurosa

Split POR VIDEO (evita fuga de datos), ground truth de conteo = nº de cajas, calibracion de umbral para conteo.

● Comparacion de modelos

YOLOv8n/s y YOLOv11n/s/m a 960/1280/1536 px. Mejor deteccion: YOLOv11m@1536 (mAP@50=0.836).

● Contador general

Un solo modelo cuenta larvas y peces grandes (otra especie) en 2 sesiones distintas. Elimina el falso positivo del recipiente.

● Tracking de video

BoT-SORT (sin compensacion de camara) supera a ByteTrack para contar por IDs unicos en camara fija.

● Estacion de captura

Diseno de un entorno controlado (luz difusa + bandeja de una capa) que ataca cada fuente de error medida.

Metrica clave para el CITE (conteo por LOTE):

El sistema cuenta un lote completo con 0.17-2.6% de error — lo que importa al contar una tanda de alevines.

1

1. Captura de datos

Videos y fotos cenitales con smartphone (4K), en distintas sesiones.



2

2. Extraccion y curacion

Extraccion de frames + deduplicacion perceptual (pHash) para quedarse con frames diversos.



3

3. Etiquetado

Pre-etiquetado automatico (IA) -> revision manual colaborativa en LabelImg -> ground truth de conteo.



4

4. Construccion del dataset

Split por video/temporal (sin leakage). Train / Val / Test + data augmentation.



5

5. Entrenamiento y ajuste

Transfer learning (COCO), comparacion de arquitecturas, resolucion e hiperparametros, calibracion de confianza.



6

6. Evaluacion

Deteccion (P, R, mAP) + conteo (MAE, RMSE, MAPE, R2, error de lote) + ablacion + generalizacion.




7


7. Resultado y despliegue

Modelo final -> conteo automatico. Tracking para video. Estacion de captura + export movil (.tflite).


Imágenes revisadas



Alevines etiquetados (cajas)




Tamaño mediano del objeto por fuente (lado equivalente)



Hallazgo: los objetos NO son pequeños (todos > 32 px). El techo del mAP@50-95 no es el tamaño, sino la generalización (ver página de la campaña mAP@50-95).


4 Comparacion de modelos (test final, 233 imgs)




Resultados de conteo (mismo test)


Modelo	mAP@50	mAP@50-95	MAPE	R2	Error lote
v11m@1536	0.836	0.506	12.5%	0.926	1.5%
v11m@1280	0.833	0.501	13.6%	0.909	6.3%
v11s@960	0.833	0.498	14.3%	0.892	6.9%
v11n@1536	0.828	0.491	10.6%	0.923	2.6%
v11n@1280	0.825	0.483	12.5%	0.936	2.6%
v8n@960	0.817	0.478	12.1%	0.907	7.0%

Recomendado: YOLOv11n@1280 (equilibrio conteo/movil). Maxima exactitud: YOLOv11m@1536.




Error de conteo (MAPE) por fuente / condicion





Diagnostico clave:

- Los modelos grandes + alta resolucion subieron el mAP@50-95 de 0.483 a 0.506 (mejora incremental).
- En el TRAIN el modelo SI alcanza 0.62 -> las etiquetas soportan >0.60.
- El limitante real es la BRECHA DE GENERALIZACION (train 0.62 -> test 0.51), no el modelo ni las etiquetas.
- Conclusion: superar 0.60 en test es alcanzable con MAS DATOS DIVERSOS (mas sesiones/condiciones), que es justamente el proximo paso del proyecto.



Conclusiones del tracking:

- BoT-SORT supera claramente a ByteTrack ($\approx 2x$ menos fragmentacion) — su Kalman mas preciso ayuda con o
- La compensacion de movimiento de camara (GMC) es inutil con tripode: misma calidad, $2x$ mas lento $\rightarrow$ usar
- A frame completo la fragmentacion baja de 4.3 a 1.89 (los peces casi no se mueven entre frames a 120 fps).
- Recomendado: BoT-SORT con `gmc_method=None`, a frame completo.

Estado del sistema

- Sistema funcional de extremo a extremo: captura -> etiquetado -> entrenamiento -> conteo.
- Contador GENERAL validado en 2 sesiones/camaras: cuenta larvas y peces grandes, sin el falso positivo del r...
- A nivel de LOTE (lo que importa al CITE) el error es de 0.17-2.6%.
- Metodologia solida y honesta: split sin fuga de datos, metricas del dominio, ablacion, analisis de fallos y de g...
- Decidido el tracker de video (BoT-SORT) y disenada la estacion de captura estandarizada.

Proximos pasos (por prioridad)

1. Mas datos diversos (2-3 sesiones nuevas con distinta luz/agua/recipiente) -> cerrar la brecha y superar 0.60
2. Armar la estacion de captura estandarizada (luz difusa + bandeja de una capa) -> menos data, mas exactitud
3. Software de la estacion: capturar -> correr YOLO -> mostrar conteo, con bucle de mejora (active learning).
4. Exportar a movil (.tflite/.onnx) y medir tamano/FPS en el dispositivo.
5. (Opcional) Segmentacion/OBB para subir aun mas el techo del mAP@50-95.

Entregables generados

- Repositorio con todo el pipeline (scripts reproducibles) y modelos entrenados.
- Informe tecnico (docs/INFORME_TECNICO.md) con metodologia, resultados y referencias verificadas.
- Diagramas: pipeline del sistema y especificacion de la estacion de captura.
- Este reporte PDF + un notebook Jupyter ejecutable con todos los procesos.